

Přenos nejistoty

Náhodná veličina y , která je funkcí náhodných proměnných x_i :

$$y = f(x_1, x_2, \dots, x_n) \quad x_i \text{ se řídí rozděleními } p_i(x_i)$$

→ můžeme najít jejich střední hodnoty μ_i a disperse σ_i^2

$$x_i = \mu_i \pm \sigma_i$$

Jak se projeví nejistoty x_i na veličině y ?

→ chceme získat odhad nejistoty veličiny y .

Funkci f lze rozvinout do Taylorovy řady v okolí bodu $\mu \equiv f(\mu_1, \mu_2, \dots, \mu_n)$:

$$y = f(\mu_1, \mu_2, \dots, \mu_n) + \sum_{i=1}^n \left(\frac{\partial f}{\partial x_i} \right)_{\mu_1, \dots, \mu_n} (x_i - \mu_i) +$$

~~$$+ \frac{1}{2!} \sum_{i,j=1}^n \left(\frac{\partial^2 f}{\partial x_i \partial x_j} \right)_{\mu_1, \dots, \mu_n} (x_i - \mu_i)(x_j - \mu_j) + \dots$$~~

(nelineární členy zanedbáme)

Přenos nejistoty

$$y \cong f(\mu_1, \mu_2, \dots, \mu_n) + \sum_{i=1}^n \left(\frac{\partial f}{\partial x_i} \right)_{\mu_1, \dots, \mu_n} (x_i - \mu_i)$$

Očekávaná hodnota: $E[y] = E[f(x_1, x_2, \dots, x_n)] \approx f(\mu_1, \mu_2, \dots, \mu_n)$

Disperze: $\sigma_y^2 = V[y] = E[y^2] - (E[y])^2$

$$\sigma_y^2 \approx \sum_{i=1}^n \sum_{j=1}^n \left(\frac{\partial f}{\partial x_i} \right)_{\mu_1, \dots, \mu_n} \left(\frac{\partial f}{\partial x_j} \right)_{\mu_1, \dots, \mu_n} \text{cov}(x_i, x_j)$$

Jsou-li x_i nezávislé:

$$\sigma_y^2 \approx \sum_{i=1}^n \left(\frac{\partial f}{\partial x_i} \right)_{\mu_1, \dots, \mu_n}^2 \sigma_{x_i}^2$$

Shrnutí: zpracování výsledků měření veličiny $y = f(x_1, x_2, \dots, x_k)$

1) Zpracování pro přímo měřené veličiny. Pro každou veličinu x_i :

a) výpočet aritm. průměru \bar{x}_i a směrodatné odchylky s_{x_i}

$$s_{x_i}^2 = \frac{1}{n_i - 1} \sum_{q=1}^{n_i} (x_{i,q} - \bar{x}_i)^2$$

b) vyloučení hrubých chyb ($> „3\sigma“$)

c) výpočet odhadu standardní odchylky aritm. průměru $s_{\bar{x}_i}$

$$s_{\bar{x}_i} = \frac{s_{x_i}}{\sqrt{n_i}}$$

d) určení chyby měřidla Δx .

(Je-li $s_{x_i} \gg \Delta x$, lze Δx zanedbat a obráceně.)

e) volba pravděpodobnosti P a určení korekce t_P (závisí na P a počtu měření n_i)

- např. $P \sim 68\%$... standardní odchylka ($„\sigma“$)

f) určení celkové střední chyby veličiny x_i : $u_{\bar{x}_i} = \sqrt{(t_P s_{\bar{x}_i})^2 + (\Delta x)^2}$

g) zaokrouhlení a zápis $x_i = \bar{x}_i \pm u_{\bar{x}_i}$

2) Výsledek pro veličinu y :

a) výpočet střední hodnoty: $\bar{y} = f(\bar{x}_1, \bar{x}_2, \dots, \bar{x}_k)$

b) výpočet celkové střední chyby:

$$u_y = \sqrt{\left(\frac{\partial f}{\partial x_1}\right)_{x_1, \dots, x_k}^2 u_{x_1}^2 + \left(\frac{\partial f}{\partial x_2}\right)_{x_1, \dots, x_k}^2 u_{x_2}^2 + \dots + \left(\frac{\partial f}{\partial x_k}\right)_{x_1, \dots, x_k}^2 u_{x_k}^2}$$

c) zaokrouhlení a zápis výsledku: $y = \bar{y} \pm u_{\bar{y}} \quad (P \sim 68\%)$

Nejistota nepřímého měření

Příklad: měření el. odporu $R = U / I$

- proměnné x_i : U, I
 - měřením U jsme získali \bar{U} a σ_U , z přesnosti přístroje: $u_{U, B}$
 $\rightarrow u_U^2 = (\sigma_{\bar{U}}^*)^2 + u_{U, B}^2$
 - měřením I jsme získali \bar{I} a σ_I , z přesnosti přístroje: $u_{I, B}$
 $\rightarrow u_I^2 = (\sigma_{\bar{I}}^*)^2 + u_{I, B}^2$
- Očekávaná hodnota: $\bar{R} = \bar{U} / \bar{I}$
- Nejistota: $u_R = \sqrt{\left(\frac{\partial R}{\partial U}\right)_{\bar{U}, \bar{I}}^2 u_U^2 + \left(\frac{\partial R}{\partial I}\right)_{\bar{U}, \bar{I}}^2 u_I^2}$
- Výsledek: $R = \bar{R} \pm u_R \quad (\Omega)$

Přenos nejistoty – typické případy

- **součet** náhodných proměnných $y = a + b$
 - a, b jsou nezávislé: $\langle y \rangle = \langle a \rangle + \langle b \rangle$
 $V(y) = V(a) + V(b)$
 - a, b nejsou nezávislé: $\langle y \rangle = \langle a \rangle + \langle b \rangle$
 $V(y) = V(a) + V(b) + 2\text{Cov}(a, b)$
- a, b nezávislé – jak vypadá **relativní nejistota**?
 - **součin / podíl:**
 $y = ab$ $\sigma_y^2 = b^2 \sigma_a^2 + a^2 \sigma_b^2$ $\eta_y^2 = \eta_a^2 + \eta_b^2$
 - **mocnina:**
 $y = a^n$ $\sigma_y^2 = (na^{n-1})^2 \sigma_a^2$ $\eta_y^2 = n^2 \eta_a^2$

Interpolace funkčních závislostí

$y = f(x_1, x_2, \dots, x_k)$... teoretická závislost (fyzikální zákon)

- V experimentu měníme hodnotu jedné nebo několika veličin x_i a studujeme závislost veličiny y .
 - např. měníme $x_1 \equiv x$, ostatní x_i bereme jako parametry ($\alpha, \beta, \gamma, \dots$):

$$y = f(x | \alpha, \beta, \gamma, \dots)$$

- Chceme posoudit platnost závislosti y na x_i z výsledků experimentu.
 - tj. chceme získat odhady parametrů $\tilde{\alpha}, \tilde{\beta}, \tilde{\gamma}, \dots$
- např. pro N hodnot x_1, x_2, \dots, x_N jsme naměřili N hodnot y_1, y_2, \dots, y_N

Předpokládáme, že známe funkční závislost f a že přesnost nastavení hodnot veličiny x je řádově větší, než přesnost měření závisle proměnné y (která má obecně pro každý bod jinou dispersi).


Metoda nejmenších čtverců

- Metoda početní interpolace.
- Používá se pro získání odhadů parametrů $(\tilde{\alpha}, \tilde{\beta}, \tilde{\gamma}, \dots)$:

1) Zkonstruuujeme veličinu

$$\chi^2(\alpha, \beta, \gamma, \dots) = \sum_{i=1}^N \frac{(f(x_i | \alpha, \beta, \gamma, \dots) - y_i)^2}{\sigma_{y_i}^2}$$

2) Hledáme minimum $\chi^2(\alpha, \beta, \gamma, \dots)$.



Metoda nejmenších čtverců – přímka procházející počátkem

- $y = mx$

- $\chi^2(m) = \sum_{i=1}^N \frac{(mx_i - y_i)^2}{\sigma_{y_i}^2}$


- minimalizace χ^2 :

$$\tilde{m} = \frac{\sum_{i=1}^N \frac{y_i x_i}{\sigma_{y_i}^2}}{\sum_{i=1}^N \frac{x_i^2}{\sigma_{y_i}^2}}$$

- disperze m: $\sigma_{\tilde{m}}^2 = \frac{1}{\sum_{i=1}^N \frac{x_i^2}{\sigma_{y_i}^2}}$

- $m = \tilde{m} \pm \sigma_{\tilde{m}}$

- problém: co když neznáme σ_{y_i}



Metoda nejmenších čtverců – přímka procházející počátkem

- Pokud jsou σ_{y_i} neznámé ale stejné, $\sigma_{y_i} = \sigma_y$

... potom
$$\sigma_{\tilde{m}}^2 = \frac{\sigma_y^2}{\sum_{i=1}^N x_i^2}$$

- Pro neznámou disperzi σ_y pak lze spočítat odhad:
$$\tilde{\sigma}_y^2 = \frac{1}{n} \sum_{i=1}^n (y_i - \tilde{m}x_i)^2$$

ozn.
$$R_1^2 \equiv \sum_{i=1}^n (y_i - \tilde{m}x_i)^2 \quad \dots \text{ minimální suma čtverců odchylek}$$

- nevychýlený odhad:
$$\left(\tilde{\sigma}_y^*\right)^2 = \frac{R_1^2}{n-1}$$

- Odhad disperze m je tedy:

$$\left(\sigma_{\tilde{m}}^*\right)^2 = \frac{1}{\sum_{i=1}^N x_i^2} \frac{R_1^2}{n-1}$$

Obecná přímka, obecná lineární regrese

- obecná přímka: $y = \beta_0 + \beta_1 x + \varepsilon$

naměřené hodnoty: $[x_i, y_i] \quad i = 1, \dots, n$

nejistoty závislé veličiny y_i : $\varepsilon_i \in N(0, \sigma)$

- minimalizace χ^2 : $\frac{\partial \chi^2}{\partial \beta_1} = 0 \quad \frac{\partial \chi^2}{\partial \beta_0} = 0$

vede na soustavu lineárních rovnic:

$$\begin{aligned} \beta_0 \sum_{i=1}^n \frac{x_i}{\varepsilon_i^2} + \beta_1 \sum_{i=1}^n \frac{x_i^2}{\varepsilon_i^2} + \sum_{i=1}^n \frac{\varepsilon_i x_i}{\varepsilon_i^2} &= \sum_{i=1}^n \frac{x_i y_i}{\varepsilon_i^2} \\ \beta_0 \sum_{i=1}^n \frac{1}{\varepsilon_i^2} + \beta_1 \sum_{i=1}^n \frac{x_i}{\varepsilon_i^2} + \sum_{i=1}^n \frac{\varepsilon_i}{\varepsilon_i^2} &= \sum_{i=1}^n \frac{y_i}{\varepsilon_i^2} \end{aligned}$$

Jak jsou parametry β_0 a β_1 (ne)závislé?
 $\rightarrow \text{Cov}(\beta_0, \beta_1)$

- obecná funkční závislost: $y = y(x, \beta_1, \dots, \beta_m)$ \leftarrow lineární v parametrech β_i tj.

$$\begin{array}{ccccccc} \beta_1 \sum_{i=1}^n f_1(x_i) f_1(x_i) & + & \dots & + & \beta_m \sum_{i=1}^n f_m(x_i) f_1(x_i) & = & \sum_{i=1}^n f_1(x_i) y_i \\ \vdots & & \ddots & & \vdots & & \\ \beta_1 \sum_{i=1}^n f_m(x_i) f_m(x_i) & + & \dots & + & \beta_m \sum_{i=1}^n f_m(x_i) f_m(x_i) & = & \sum_{i=1}^n f_m(x_i) y_i \end{array} \qquad y = \sum_{k=1}^m \beta_k f_k(x)$$

Maticové vyjádření

$$y = \sum_{k=1}^m \beta_k f_k(x)$$

Naměřené hodnoty: $\mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix}$ $\mathbf{y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}$

$$\mathbf{y} = \mathbf{A}\boldsymbol{\beta}$$

Hledané parametry: $\boldsymbol{\beta} = \begin{pmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_m \end{pmatrix}$

Matice plánu (konstrukční matice, design matrix):

$$\mathbf{A} = \begin{pmatrix} f_1(x_1) & \cdots & f_m(x_1) \\ \vdots & \ddots & \vdots \\ f_1(x_n) & \cdots & f_m(x_n) \end{pmatrix} \quad \leftarrow \text{matice } m \times n, m \leq n$$

$$\frac{\partial}{\partial \boldsymbol{\beta}} \|\mathbf{A}\boldsymbol{\beta} - \mathbf{y}\|^2 = 0 \quad \rightarrow \text{řešení pro parametry: } \boldsymbol{\beta} = (\mathbf{A}^T \mathbf{A})^{-1} \mathbf{A}^T \mathbf{y} = \mathbf{H}\mathbf{y}$$

Jak jsou parametry (ne)závislé?
 $\text{Cov}(\beta_0, \beta_1)$

\rightarrow kovarianční matice:

$$U_{ij} = \text{Cov}(\beta_i, \beta_j) \\ V_{ij} = \text{Cov}(y_i, y_j)$$

$$\mathbf{U} = \mathbf{H}\mathbf{V}\mathbf{H}^T$$

Fitování

- Konstrukce křivky (funkce), která co nejlépe odpovídá naměřeným hodnotám.
 - může podléhat dodatečným podmínkám
- Lineární vs. nelineární regrese
 - metoda největšího spádu
 - Gaussova-Newtonova metoda
 - algoritmus Levenberg–Marquardt
 - simplex
- Interpolace a vyhlazování (spline)
- Regresní analýza a extrapolace
- Softwarové nástroje
 - Excel, Matlab, Origin, ...
 - gnuplot, Python, R, ...

