

# Centrální limitní věta

- $x_i$  náhodná proměnná s hustotou pravděpodobnosti  $f_i(x)$
- $x_i$  nezávislé





$$E[x_i] = \mu_i \quad V[x_i] = \sigma_i^2$$

$$y = \sum_{i=1}^N x_i \quad \text{pro } N \rightarrow \infty \text{ je } y \in N\left(\sum_{i=1}^N \mu_i, \sum_{i=1}^N \sigma_i^2\right)$$

$$\frac{y - \sum_{i=1}^N \mu_i}{\sqrt{\sum_{i=1}^N \sigma_i^2}} \rightarrow N(0,1)$$

# Centrální limitní věta

$$\sum_{i=1}^n x_i$$
$$x_i \in U(0,1)$$





# Hustota pravděpodobnosti – případ dvou proměnných

**marginální hustoty pravděpodobnosti:**

$$f_y(y) = \int_{-\infty}^{\infty} f(x, y) dx$$

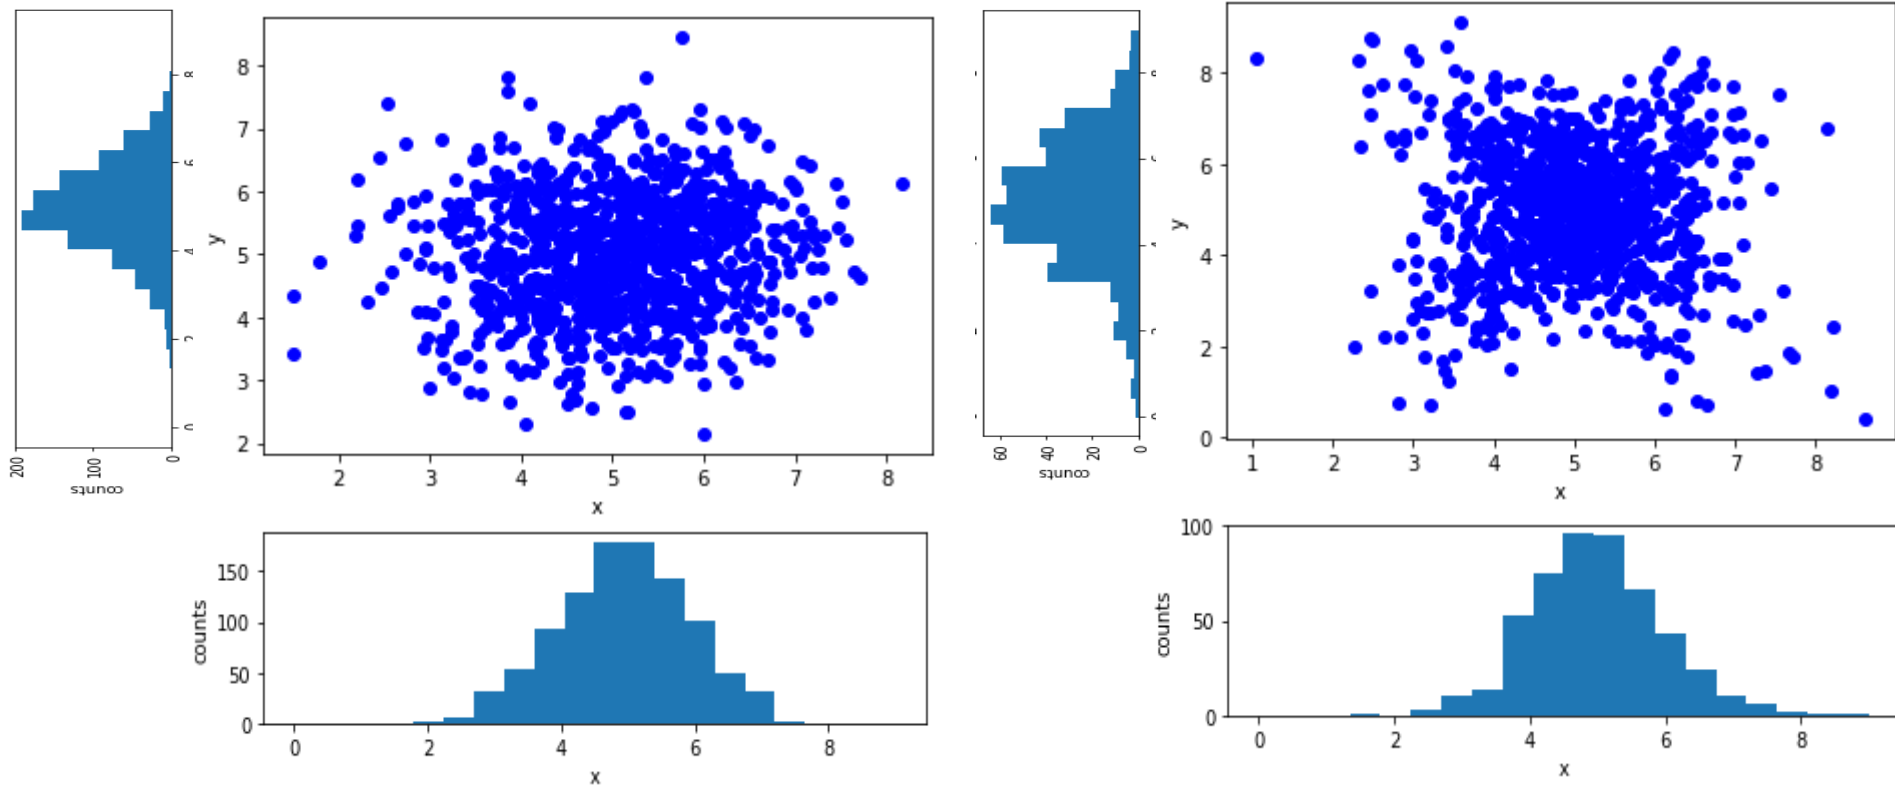
$$f_x(x) = \int_{-\infty}^{\infty} f(x, y) dy$$



# Hustota pravděpodobnosti – případ dvou proměnných

nezávislé náhodné proměnné

$$x, y \text{ jsou nezávislé} \Leftrightarrow f(x, y) = f_x(x)f_y(y)$$



# Hustota pravděpodobnosti – případ dvou proměnných

operátor **očekávané hodnoty** :  $E[ \ ]$

**očekávaná hodnota** náhodné proměnné  $x$  :  $\mu_x \equiv E[x] = \iint x f(x, y) dx dy$

**očekávaná hodnota** náhodné proměnné  $y$  :  $\mu_y \equiv E[y] = \iint y f(x, y) dx dy$

obecně :  $E[g(x, y)] = \iint g(x, y) f(x, y) dx dy$



# Hustota pravděpodobnosti – případ dvou proměnných

**rozptyl** náhodné proměnné  $x$  :  $\sigma_x^2 \equiv V[x] = E[(x - \mu_x)^2] = \iint (x - \mu_x)^2 f(x, y) dx dy$

**rozptyl** náhodné proměnné  $y$  :  $\sigma_y^2 \equiv V[y] = E[(y - \mu_y)^2] = \iint (y - \mu_y)^2 f(x, y) dx dy$

minimální smysluplná informace o náhodných proměnných  $x, y$  :  $\mu_x, \mu_y$  (míra polohy)  
 $\sigma_x, \sigma_y$  (míra disperze)

4 čísla nestačí





# Hustota pravděpodobnosti – případ dvou proměnných

**rozptyl** náhodné proměnné  $x$  :  $\sigma_x^2 \equiv V[x] = E[(x - \mu_x)^2] = \iint (x - \mu_x)^2 f(x, y) dx dy$

**rozptyl** náhodné proměnné  $y$  :  $\sigma_y^2 \equiv V[y] = E[(y - \mu_y)^2] = \iint (y - \mu_y)^2 f(x, y) dx dy$

minimální smysluplná informace o náhodných proměnných  $x, y$  :  $\mu_x, \mu_y$  (míra polohy)  
 $\sigma_x, \sigma_y$  (míra disperze)  
kovariance  $\text{cov}(x, y)$



# Hustota pravděpodobnosti – případ dvou proměnných

**kovariance** náhodných proměnných  $x$  a  $y$  :

$$\text{cov}(x, y) = E[(x - \mu_x)(y - \mu_y)] = E[xy] - E[x]E[y]$$

$$\text{cov}(x, x) = E[(x - \mu_x)^2] = \sigma_x^2$$

$$\text{cov}(y, y) = E[(y - \mu_y)^2] = \sigma_y^2$$

**kovarianční matice**  $V = \begin{pmatrix} \text{cov}(x, x) & \text{cov}(x, y) \\ \text{cov}(y, x) & \text{cov}(y, y) \end{pmatrix} = \begin{pmatrix} \sigma_x^2 & \text{cov}(x, y) \\ \text{cov}(x, y) & \sigma_y^2 \end{pmatrix}$

**korelace** náhodných proměnných  $x$  a  $y$  :  $\rho(x, y) = \frac{\text{cov}(x, y)}{\sigma_x \sigma_y}$

$$\rho(x, x) = 1$$


$$\rho(y, y) = 1$$

**korelační matice**  $R = \begin{pmatrix} \rho(x, x) & \rho(x, y) \\ \rho(y, x) & \rho(y, y) \end{pmatrix} = \begin{pmatrix} 1 & \rho(x, y) \\ \rho(x, y) & 1 \end{pmatrix}$




# Korelace náhodných proměnných

$$\rho(x,y) = 0.0$$




$$\rho(x,y) = 0.7$$




$N = 10000$

# Korelace náhodných proměnných

$$\rho(x,y) = -0.7$$



$$\rho(x,y) = 0.96$$



$N = 10000$

# Hustota pravděpodobnosti – případ dvou proměnných

**nezávislé** náhodné proměnné  $x, y$  :  $f(x, y) = f_x(x)f_y(y)$

$$\begin{aligned}\text{cov}(x, y) &= E[(x - \mu_x)(y - \mu_y)] = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} (x - \mu_x)(y - \mu_y) f(x, y) dx dy = \\ &= \int_{-\infty}^{\infty} (x - \mu_x) f_x(x) dx \int_{-\infty}^{\infty} (y - \mu_y) f_y(y) dy = E[(x - \mu_x)] E[(y - \mu_y)] = 0\end{aligned}$$

$$\text{cov}(x, y) = 0$$

kovarianční matice:  $V = \begin{pmatrix} \sigma_x^2 & 0 \\ 0 & \sigma_y^2 \end{pmatrix}$

$$\rho(x, y) = 0$$

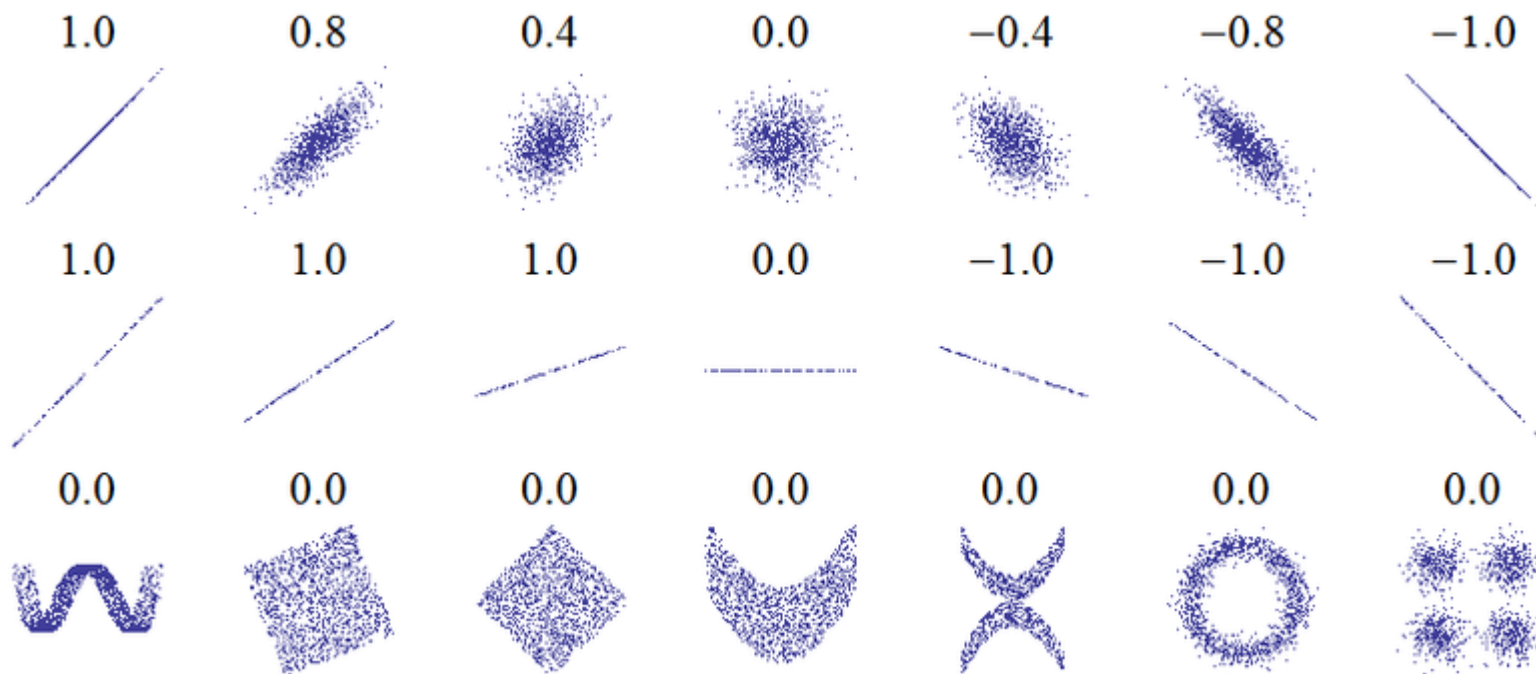
korelační matice:  $R = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$

# Hustota pravděpodobnosti – případ dvou proměnných

**nezávislé** náhodné proměnné  $x, y \Rightarrow \text{cov}(x, y) = 0, \rho(x, y) = 0$

obráceně to neplatí

Nulová korelace je nutná, ale ne postačující podmínka nezávislosti.



# Odhad kovariance a korelace

náhodné proměnné  $x, y$

- naměříme  $x_1, x_2, \dots, x_N; y_1, y_2, \dots, y_N$
- $\text{cov}(x, y)$  ???

$$\text{cov}(x, y) = E[xy] - E[x]E[y]$$

$$\hat{\text{cov}}(x, y) = \langle xy \rangle - \langle x \rangle \langle y \rangle$$

$$\hat{\rho}(x, y) = \frac{\langle xy \rangle - \langle x \rangle \langle y \rangle}{\sigma_x \sigma_y}$$

$$\hat{\rho}(x, y) = \frac{\langle xy \rangle - \langle x \rangle \langle y \rangle}{\hat{\sigma}_x \hat{\sigma}_y} \quad \sigma_{\hat{\rho}} \approx \frac{1 - \hat{\rho}^2}{\sqrt{N-1}}$$

$$\langle xy \rangle = \frac{1}{N} \sum_{i=1}^N x_i y_i$$

$$\langle x \rangle = \frac{1}{N} \sum_{i=1}^N x_i$$

$$\langle y \rangle = \frac{1}{N} \sum_{i=1}^N y_i$$

$$\hat{\sigma}_x = \sqrt{\frac{1}{N-1} \sum_{i=1}^N (x_i - \langle x \rangle)^2}$$

$$\hat{\sigma}_y = \sqrt{\frac{1}{N-1} \sum_{i=1}^N (y_i - \langle y \rangle)^2}$$

# Test korelace – Fisherova transformace

náhodné proměnné  $x, y$

• naměříme  $x_1, x_2, \dots, x_N; y_1, y_2, \dots, y_N$  → dostaneme odhad korelace  $\hat{\varrho}$

• je korelace statisticky významná?

• nulová hypotéza  $H_0$  (zde nulová korelace)

• testovací statistika  $t$


• známé rozdělení  $f(t|H_0)$

• **Fisherova transformace**  $F(\varrho) = \frac{1}{2} \ln \frac{1 + \varrho}{1 - \varrho}$

Pokud platí nulová hypotéza, tak má normální rozdělení  
s očekávanou hodnotou 0 a standardní odchylkou  $\sigma = \frac{1}{\sqrt{N-3}}$

•  $z$  - proměnná  $z = \frac{F(\varrho)}{\sigma}$

• pokud platí nulová hypotéza  $z \in N(0, 1)$



$P$  - hodnota  
pokud je  $P < P_\alpha$   
odmítneme  $H_0$

$P_\alpha$  hladina signifikance, buď 5% nebo 1%

$$P = 2(1 - F_{0,1}(z)) = 2 \left( 1 - \frac{1}{2} \left[ 1 + \operatorname{erf} \left( \frac{z}{\sqrt{2}} \right) \right] \right)$$

# Test korelace – studentovo rozdělení


náhodné proměnné  $x, y$

- naměříme  $x_1, x_2, \dots, x_N; y_1, y_2, \dots, y_N$  → dostaneme odhad korelace  $\hat{\varrho}$
- je korelace statisticky významná?
- nulová hypotéza  $H_0$  (zde nulová korelace)
- testovací statistika  $t = \hat{\varrho} \sqrt{\frac{N-2}{1-\hat{\varrho}^2}}$
- pokud platí nulová hypotéza  $t \in T(x|N-2)$

Studentovo rozdělení s počtem stupňů volnosti  $\nu = N - 2$

# Studentovo $t$ rozdělení

William Sealy Gosset



studentovo rozdělení s  $\nu$  stupni volnosti

$$f(x|\nu) = \frac{\Gamma\left(\frac{\nu+1}{2}\right)}{\sqrt{\nu\pi} \Gamma\left(\frac{\nu}{2}\right)} \left(1 + \frac{x^2}{\nu}\right)^{-\frac{\nu+1}{2}}$$

$\nu$  – počet stupňů volnosti

Gama funkce  $\Gamma(x) = \int_0^{\infty} t^{x-1} e^{-t} dt \quad x \geq 0$

$$\Gamma\left(\frac{1}{2}\right) = \sqrt{\pi}$$

$$\Gamma(n) = (n-1)! \quad n \in \mathcal{N}$$


$$\Gamma(x+1) = x\Gamma(x) \quad x \in \mathcal{R}$$

ROOT: `ROOT::Math::tgamma(x)`

Excel: `EXP(GAMMALN(x))`

Gnuplot: `gamma(x)`

Python: `from scipy.special import gamma`






# Studentovo $t$ rozdělení

Python:

```
from scipy.stats import t  
t.pdf(x, v)
```

ROOT:

```
ROOT::Math::tdistribution_pdf(x, v)
```



studentovo rozdělení s  $\nu$  stupni volnosti

$$f(x|\nu) = \frac{\Gamma\left(\frac{\nu+1}{2}\right)}{\sqrt{\nu\pi} \Gamma\left(\frac{\nu}{2}\right)} \left(1 + \frac{x^2}{\nu}\right)^{-\frac{\nu+1}{2}}$$

$\nu$  – počet stupňů volnosti

$$f(x|\nu=1) = \frac{1}{\pi} \frac{1}{1+x^2}$$

$$\nu \rightarrow \infty \quad f(x|\nu) \rightarrow N(0, 1)$$

$$E[x] = \mu = 0$$

$$V[x] = \sigma^2 = \frac{\nu}{\nu-2} \quad \nu > 2$$

# Test korelace – studentovo rozdělení

náhodné proměnné  $x, y$

• naměříme  $x_1, x_2, \dots, x_N; y_1, y_2, \dots, y_N$  → dostaneme odhad korelace  $\hat{\varrho}$

• je korelace statisticky významná?

• nulová hypotéza  $H_0$  (zde nulová korelace)


• testovací statistika  $t = \hat{\varrho} \sqrt{\frac{N-2}{1-\hat{\varrho}^2}}$

• pokud platí nulová hypotéza  $t \in T(N-2)$

Studentovo rozdělení s počtem stupňů volnosti  $\nu = N - 2$

•  $P$ -hodnota:  $P = 2(1 - T_\nu(t))$

↑ distribuční funkce studentova rozdělení



$P_\alpha$

oboustranná  $P$ -hodnota

# Test korelace – studentovo rozdělení

náhodné proměnné  $x, y$


• naměříme  $x_1, x_2, \dots, x_N; y_1, y_2, \dots, y_N$  → dostaneme odhad korelace  $\hat{\rho}$

• je korelace statisticky významná?

• nulová hypotéza  $H_0$  (zde nulová korelace)

• testovací statistika  $t = \hat{\rho} \sqrt{\frac{N-2}{1-\hat{\rho}^2}}$

• pokud platí nulová hypotéza  $t \in T(N-2)$



Studentovo rozdělení s počtem stupňů volnosti  $\nu = N - 2$

•  $P$ -hodnota:  $P = 2(1 - T_\nu(t))$   
↑ distribuční funkce studentova rozdělení

• konfidenční interval:  $\left(-T_\nu^{-1}\left(1 - \frac{P}{2}\right), T_\nu^{-1}\left(1 - \frac{P}{2}\right)\right)$   
↑ inverzní funkce k distribuční funkci studentova rozdělení