

# Metoda nejmenších čtverců - linearizace


- modelová funkce:  $\lambda(x, \theta)$

- parametry:  $\theta_1, \theta_2, \dots, \theta_m$

- nelineární model:

$$\lambda(x|\theta) = \nu_0 \exp\left(-\frac{Q}{kT}\right) \quad \theta = (\nu_0, Q)$$

$$\frac{\partial \chi^2}{\partial Q} = 0 \quad \frac{\partial \chi^2}{\partial \nu_0} = 0 \quad \begin{array}{l} \text{soustava} \\ \text{nelineárních} \\ \text{rovníc} \end{array}$$




$$\chi^2(\theta|y) = \sum_{i=1}^N \frac{(y_i - \lambda(x_i|\theta))^2}{\sigma_i^2}$$

- lineární model:

$$\ln \lambda = -\frac{Q}{kT} + \ln \nu_0 = A \frac{1}{T} + B$$

$$\frac{\partial \chi^2}{\partial A} = 0 \quad \frac{\partial \chi^2}{\partial B} = 0 \quad \begin{array}{l} \text{soustava} \\ \text{lineárních} \\ \text{rovníc} \end{array}$$



# Metoda nejmenších čtverců - linearizace


- modelová funkce:  $\lambda(x, \theta)$

- parametry:  $\theta_1, \theta_2, \dots, \theta_m$

- nelineární model:

$$\lambda(x|\theta) = \nu_0 \exp\left(-\frac{Q}{kT}\right) \quad \theta = (\nu_0, Q)$$

$$\frac{\partial \chi^2}{\partial Q} = 0 \quad \frac{\partial \chi^2}{\partial \nu_0} = 0 \quad \text{soustava nelineárních rovnic}$$




$$\chi^2(\theta|y) = \sum_{i=1}^N \frac{[\ln y_i - \ln \lambda(x_i|\theta)]^2}{\frac{\sigma_i^2}{y_i^2}}$$

- lineární model:

$$\ln \lambda = -\frac{Q}{kT} + \ln \nu_0 = A \frac{1}{T} + B$$

je nutné transformovat také chyby  $z_i = \ln y_i \quad \sigma_{z_i} = \frac{1}{y_i} \sigma_i$



# Metoda nejmenších čtverců - linearizace


- modelová funkce:  $\lambda(x, \theta)$

- parametry:  $\theta_1, \theta_2, \dots, \theta_m$

- nelineární model:

$$\lambda(x|\theta) = \nu_0 \exp\left(-\frac{Q}{kT}\right) \quad \theta = (\nu_0, Q)$$

$$\frac{\partial \chi^2}{\partial Q} = 0 \quad \frac{\partial \chi^2}{\partial \nu_0} = 0 \quad \text{soustava nelineárních rovnic}$$




Arrhenius.py

$$\chi^2(\theta|y) = \sum_{i=1}^N \frac{[\ln y_i - \ln \lambda(x_i|\theta)]^2}{\frac{\sigma_i^2}{y_i^2}}$$

- lineární model:

$$\ln \lambda = -\frac{Q}{kT} + \ln \nu_0 = A \frac{1}{T} + B$$

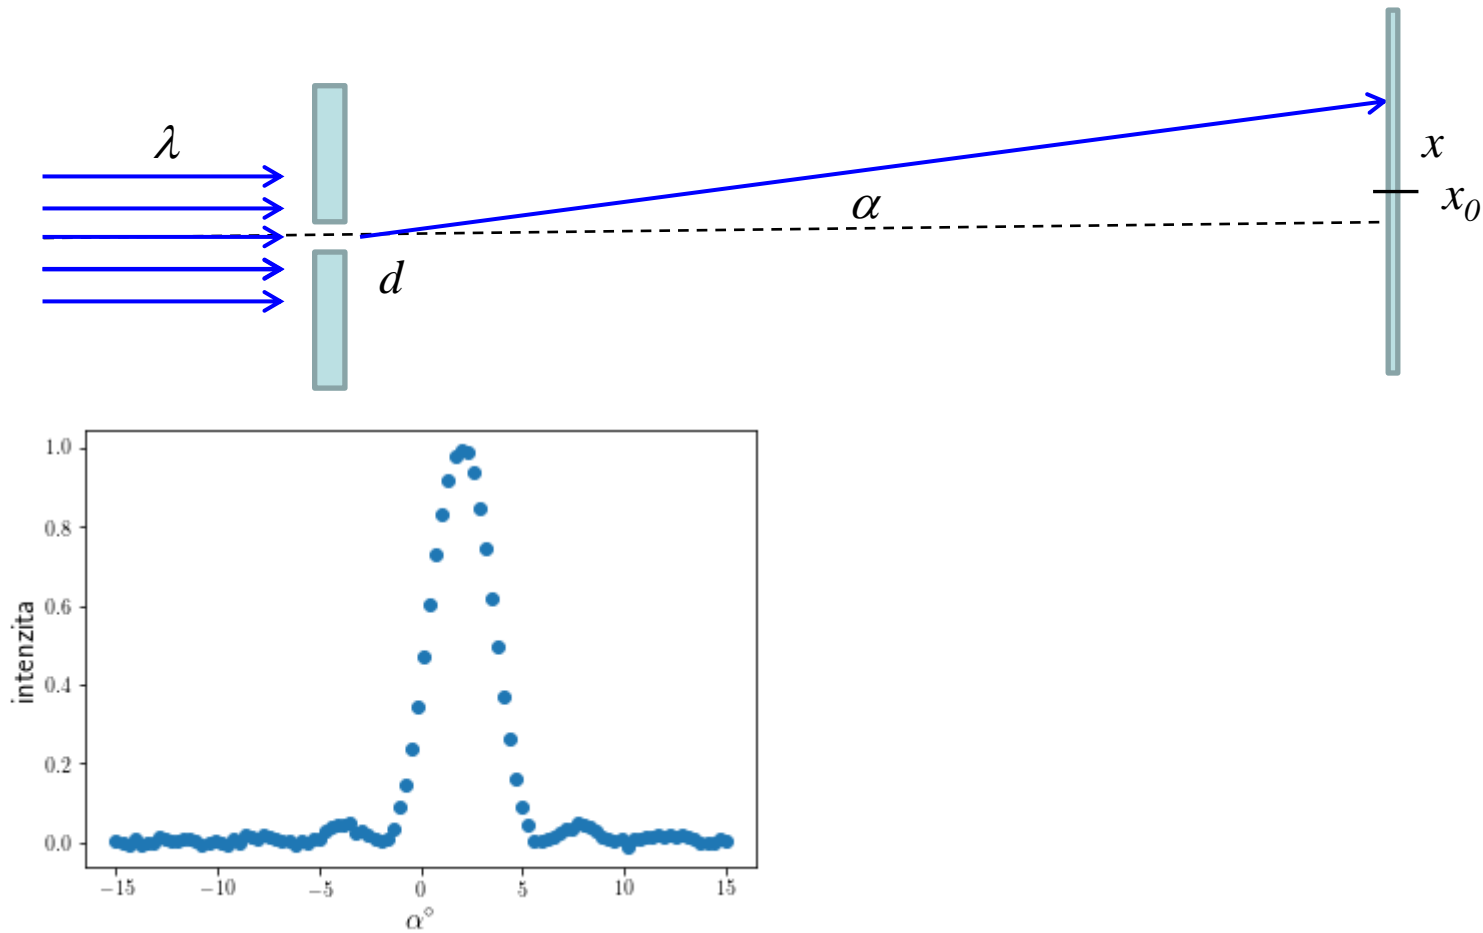
je nutné transformovat chyby  $z_i = \ln y_i$   $\sigma_{z_i} = \frac{1}{y_i} \sigma_i$



Python: funkce `np.polyfit`

# Metoda nejmenších čtverců – nelineární fit

- difrakce na štěrbíně



# Metoda nejmenších čtverců – nelineární fit



- difrakce na štěrbíně

- modelová funkce:  $\lambda(\alpha|d, \alpha_0) = \left[ \text{sinc} \left( \frac{\pi d}{\lambda} \sin(\alpha - \alpha_0) \right) \right]^2$
- $\text{sinc}(x) = \frac{\sin x}{x}$
- šířka štěrbiny
- poloha hlavního maxima

$$\chi^2(d, \alpha_0 | y) = \sum_{i=1}^N \frac{[y_i - \lambda(\alpha_i | d, \alpha_0)]^2}{\sigma_i^2}$$

$$d = (2.499 \pm 0.004) \mu\text{m}$$

$$\alpha_0 = (1.999 \pm 0.003)^\circ$$




Python: funkce `np.curve_fit`  
`sterbina.py`

# Metoda nejmenších čtverců – nelineární fit

- difrakce na dvojštěrbíně

- modelová funkce:  $I(\alpha|d, b, \alpha_0) = \left[ \text{sinc} \left( \frac{\pi d}{\lambda} \sin(\alpha - \alpha_0) \right) \right]^2 \left[ \cos \left( \frac{\pi b}{\lambda} \sin(\alpha - \alpha_0) \right) \right]^2$




$$\text{sinc}(x) = \frac{\sin x}{x}$$

šířka štěrbin

vzdálenost štěrbin

poloha hlavního maxima



# Metoda nejmenších čtverců – nelineární fit

- difrakce na dvojštěrbíně



- modelová funkce:  $\lambda(\alpha|d, b, \alpha_0) = \left[ \text{sinc} \left( \frac{\pi d}{\lambda} \sin(\alpha - \alpha_0) \right) \right]^2 \left[ \cos \left( \frac{\pi b}{\lambda} \sin(\alpha - \alpha_0) \right) \right]^2$   
Annotations:
  - širka štěrbin (points to  $d$ )
  - vzdálenost štěrbin (points to  $b$ )
  - poloha hlavního maxima (points to  $\alpha_0$ )
  - $\text{sinc}(x) = \frac{\sin x}{x}$  (points to the sinc function)

$$\chi^2(d, b, \alpha_0|y) = \sum_{i=1}^N \frac{[y_i - \lambda(\alpha_i|d, b, \alpha_0)]^2}{\sigma_i^2}$$

$$d = (0.4998 \pm 0.0004) \mu\text{m}$$


$$b = (5.999 \pm 0.001) \mu\text{m}$$

$$\alpha_0 = (2.001 \pm 0.001)^\circ$$



Python: funkce `np.curve_fit`  
`dvojsterbina.py`

# Newton – Raphsonův algoritmus



- iterativní metoda jak najít minimum  $\chi^2$

1. zvol počáteční odhad parametrů  $\theta_0 = (\theta_{1_0}, \theta_{2_0}, \dots, \theta_{m_0})$

2. Spočítej totální diferenciál  $\chi^2$  v bodě  $\theta_0$   $A_i = \nabla \chi^2(\theta|y)_i = \left. \frac{\partial \chi^2}{\partial \theta_i} \right|_{\theta_0}$  vektor ( $m \times 1$ )

a Hesseovu matici  $\chi^2$  v bodě  $\theta_0$   $H_{i,j} = \nabla^2 \chi^2(\theta|y)_{i,j} = \left. \frac{\partial^2 \chi^2}{\partial \theta_i \partial \theta_j} \right|_{\theta_0}$  (matice  $m \times m$ )

3. Spočítej upřesněný odhad  $\theta_1 = \theta_0 - H^{-1}A$

inverzní matice k Hesseově  
matici v bodě  $\theta_0$

totální diferenciál v bodě  $\theta_0$


polož  $\theta_0 = \theta_1$

opakuji dokud  $\nabla \chi^2(\theta|y) = \left. \frac{\partial \chi^2}{\partial \theta_1} \right|_{\theta_0} = 0$



# Metoda nejmenších čtverců – chyby obou proměnných

- jak  $x$ , tak  $y$  jsou náhodné proměnné
- $\sigma_x$  - chyby  $x$ ,  $\sigma_y$  – chyby  $y$



# Metoda nejmenších čtverců – chyby obou proměnných

- jak  $x$ , tak  $y$  jsou náhodné proměnné
- $\sigma_x$  - chyby  $x$ ,  $\sigma_y$  - chyby  $y$

- $d_i$  - vzdálenost bodu  $[x_i, y_i]$  od modelové funkce

$$d_i^2 = (x_i - \tilde{x})^2 + (y_i - f(\tilde{x}))^2$$

- „vážená“ vzdálenost bodu  $[x_i, y_i]$  od modelové funkce

$$d_i^2 = \frac{1}{\sigma_{x_i}^2} (x_i - \tilde{x})^2 + \frac{1}{\sigma_{y_i}^2} (y_i - f(\tilde{x}))^2$$

- Taylorův rozvoj modelové funkce  $f(x) \approx f(x_i) + f'(x_i)(x - x_i)$


$$d_i^2 = \frac{1}{\sigma_{x_i}^2} (x_i - \tilde{x})^2 + \frac{1}{\sigma_{y_i}^2} (y_i - f(x_i) - f'(x_i)(\tilde{x} - x_i))^2$$

- zjistíme pro jaké  $\tilde{x}$  je „vážená“ vzdálenost minimální

$$\frac{\partial d_i^2}{\partial \tilde{x}} = -2 \frac{1}{\sigma_{x_i}^2} (x_i - \tilde{x}) - 2 \frac{1}{\sigma_{y_i}^2} (y_i - f(x_i) - f'(x_i)(\tilde{x} - x_i)) f'(x_i) = 0$$


$$(x_i - \tilde{x}) = \frac{-\frac{1}{\sigma_{y_i}^2} (y_i - f(x_i)) f'(x_i)}{\frac{1}{\sigma_{x_i}^2} + \frac{1}{\sigma_{y_i}^2} f'^2(x_i)}$$

dosadíme do  $d_i^2$



# Metoda nejmenších čtverců – chyby obou proměnných

- jak  $x$ , tak  $y$  jsou náhodné proměnné
- $\sigma_x$  - chyby  $x$ ,  $\sigma_y$  - chyby  $y$



- $d_i$  - vzdálenost bodu  $[x_i, y_i]$  od modelové funkce

$$d_i^2 = (x_i - \tilde{x})^2 + (y_i - f(\tilde{x}))^2$$

- „vážená“ vzdálenost bodu  $[x_i, y_i]$  od modelové funkce

$$d_i^2 = \frac{1}{\sigma_{x_i}^2} (x_i - \tilde{x})^2 + \frac{1}{\sigma_{y_i}^2} (y_i - f(\tilde{x}))^2$$

- Taylorův rozvoj modelové funkce  $f(x) \approx f(x_i) + f'(x_i)(x - x_i)$

$$d_i^2 = \frac{1}{\sigma_{x_i}^2} (x_i - \tilde{x})^2 + \frac{1}{\sigma_{y_i}^2} (y_i - f(x_i) - f'(x_i)(\tilde{x} - x_i))^2$$

- zjistíme pro jaké  $\tilde{x}$  je „vážená“ vzdálenost minimální

$$\frac{\partial d_i^2}{\partial \tilde{x}} = -2 \frac{1}{\sigma_{x_i}^2} (x_i - \tilde{x}) - 2 \frac{1}{\sigma_{y_i}^2} (y_i - f(x_i) - f'(x_i)(\tilde{x} - x_i)) f'(x_i) = 0$$


$$(x_i - \tilde{x}) = \frac{-\frac{1}{\sigma_{y_i}^2} (y_i - f(x_i)) f'(x_i)}{\frac{1}{\sigma_{x_i}^2} + \frac{1}{\sigma_{y_i}^2} f'^2(x_i)}$$

$$\rightarrow d_i^2 = \frac{\frac{1}{\sigma_{x_i}^2} \frac{1}{\sigma_{y_i}^2} (y_i - f(x_i))^2}{\frac{1}{\sigma_{x_i}^2} + \frac{1}{\sigma_{y_i}^2} f'^2(x_i)} = \frac{(y_i - f(x_i))^2}{\sigma_{y_i}^2 + \sigma_{x_i}^2 f'^2(x_i)}$$

dosadíme do  $d_i^2$

# Metoda nejmenších čtverců – chyby obou proměnných

- jak  $x$ , tak  $y$  jsou náhodné proměnné
- „vážená“ vzdálenost bodu  $[x_i, y_i]$  od modelové funkce
- $\sigma_x$  - chyby  $x$ ,  $\sigma_y$  - chyby  $y$



$$d_i^2 = \frac{(y_i - f(x_i))^2}{\sigma_{y_i}^2 + \sigma_{x_i}^2 f'^2(x_i)}$$

$$\chi^2(\theta|y) = \sum_{i=1}^N d_i^2 = \sum_{i=1}^N \frac{(y_i - f(x_i))^2}{\sigma_{y_i}^2 + \sigma_{x_i}^2 f'^2(x_i)}$$

- minimalizace  $\chi^2$

$$y = f(x) \quad x \longrightarrow x + dx$$

- Taylorův rozvoj

$$f(x + dx) = f(x) + f'(x)dx = y + f'(x)dx$$

- celková chyba  $\sigma^2 = \sigma_y^2 + f'(x)^2 \sigma_x^2$


# Lineární regrese – chyby obou proměnných

- jak  $x$ , tak  $y$  jsou náhodné proměnné
- $\sigma_x$  - chyby  $x$ ,  $\sigma_y$  - chyby  $y$
- modelová funkce  $f(x|a, b) = ax + b$

$$\chi^2(\theta|y) = \sum_{i=1}^N \frac{(y_i - f(x_i))^2}{\sigma_{y_i}^2 + \sigma_{x_i}^2 f'^2(x_i)}$$

$$f(x_i|a, b) = ax_i + b \quad f'(x_i) = a$$

$$\chi^2(\theta|y) = \sum_{i=1}^N \frac{(y_i - ax_i - b)^2}{\sigma_{y_i}^2 + a^2 \sigma_{x_i}^2}$$




# Lineární regrese – chyby obou proměnných

- jak  $x$ , tak  $y$  jsou náhodné proměnné
- $\sigma_x$  - chyby  $x$ ,  $\sigma_y$  - chyby  $y$
- modelová funkce  $f(x|a, b) = ax + b$

$$\chi^2(\theta|y) = \sum_{i=1}^N \frac{(y_i - f(x_i))^2}{\sigma_{y_i}^2 + \sigma_{x_i}^2 f'^2(x_i)}$$

$$f(x_i|a, b) = ax_i + b \quad f'(x_i) = a$$

$$\chi^2(\theta|y) = \sum_{i=1}^N \frac{(y_i - ax_i - b)^2}{\sigma_{y_i}^2 + a^2 \sigma_{x_i}^2}$$



# Lineární regrese – chyby obou proměnných

- jak  $x$ , tak  $y$  jsou náhodné proměnné
- $\sigma_x$  - chyby  $x$ ,  $\sigma_y$  - chyby  $y$
- modelová funkce  $f(x|a, b) = ax + b$

$$\chi^2(\theta|y) = \sum_{i=1}^N \frac{(y_i - f(x_i))^2}{\sigma_{y_i}^2 + \sigma_{x_i}^2 f'^2(x_i)}$$

$$f(x_i|a, b) = ax_i + b \quad f'(x_i) = a$$

$$\chi^2(\theta|y) = \sum_{i=1}^N \frac{(y_i - ax_i - b)^2}{\sigma_{y_i}^2 + a^2 \sigma_{x_i}^2}$$

