

Testování hypotéz – test korelace

- náhodné proměnné x a y
- naměříme hodnoty x_1, x_2, \dots, x_N a y_1, y_2, \dots, y_N
- vypočítáme odhad korelace: $\hat{\rho}(x, y) = \frac{\langle xy \rangle - \langle x \rangle \langle y \rangle}{\hat{\sigma}_x \hat{\sigma}_y}$ s chybou: $\hat{\sigma}_\rho \approx \frac{1 - \hat{\rho}^2}{\sqrt{N - 1}}$
- **Je korelace statisticky významná?**

- použijeme **testovací statistiku** $f(t|H_0)$

známá hustota pravděpodobnosti $f(t)$ a distribuční funkce $F(t)$

transformace $\rho \rightarrow t$ (nová **testovací proměnná** t)

nulová hypotéza H_0 (předpoklad nulové korelace proměnných x a y)

hladina signifikance P_α (typicky 5 % nebo 1 %), pro $P < P_\alpha$ odmítneme H_0

$$P = P(t > \hat{t}(\hat{\rho})) = 1 - F(\hat{t}(\hat{\rho}))$$

Test korelace – Fisherova transformace

- Fisherova transformace**

transformace

$$z = \frac{1}{2} \ln \frac{1 + \rho}{1 - \rho}$$

Pokud platí nulová hypotéza, má proměnná z normální rozdělení $N(\mu, \sigma)$,

kde očekávaná hodnota $\mu = 0$ a standardní odchylka $\sigma = 1/\sqrt{N-3}$.

testovací proměnná

$$t = \frac{z}{\sigma} = \frac{\sqrt{N-3}}{2} \ln \frac{1 + \rho}{1 - \rho}$$

Pokud platí nulová hypotéza, má proměnná t normální rozdělení $N(0,1)$.

t-hodnota

$$\hat{t}(\hat{\rho}) = \frac{\sqrt{N-3}}{2} \ln \frac{1 + \rho}{1 - \rho}$$

Test korelace – Fisherova transformace

- **Fisherova transformace**

testovací statistika

$$f(t|H_0) = N(0,1) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{t^2}{2}\right)$$

nulová hypotéza H_0

Náhodné proměnné x a y jsou NEZÁVISLÉ.

hladina signifikance P_α

Pro $P > P_\alpha$

přijmeme nulovou hypotézu.

Pro $P < P_\alpha$

odmítneme nulovou hypotézu.

pravděpodobnost

$$P = P(|t| > \hat{t}(\hat{\rho})) = 2[1 - F(|\hat{t}(\hat{\rho})|)] = 2 \left\{ 1 - \frac{1}{2} \left[1 + \operatorname{erf}\left(\frac{|\hat{t}(\hat{\rho})|}{\sqrt{2}}\right) \right] \right\}$$

Test korelace – Fisherova transformace

- Fisherova transformace

Příklad: $N = 39$, proměnné x, y, z

$$\hat{\rho}(x, y) = 0.694$$

$$|\hat{t}_{x,y}| = 5.137$$

$$P_{x,y} = 3 \times 10^{-7}$$

$$\hat{\rho}(x, z) = -0.111$$


$$|\hat{t}_{x,z}| = 0.669$$

$$P_{x,y} = 0.50$$

$$\hat{\rho}(x, y) = 0.059$$

$$|\hat{t}_{y,z}| = 0.355$$

$$P_{x,y} = 0.72$$



$P < 5\%$ **odmítneme** nulovou hypotézu

Proměnné x, y jsou **ZÁVISLÉ**.

$P > 5\%$ **přijmeme** nulovou hypotézu

Proměnné x, z a y, z jsou **NEZÁVISLÉ**.

Test korelace – studentovo rozdělení

- **studentovo rozdělení**

transformace

$$t = \rho \sqrt{\frac{N - 2}{1 - \rho^2}}$$

← testovací proměnná, t-hodnota

Pokud platí nulová hypotéza, má proměnná t studentovo rozdělení s $N - 2$ stupni volnosti.

testovací statistika

studentovo rozdělení s ν stupni volnosti

$$f(x|\nu) = \frac{\Gamma\left(\frac{\nu+1}{2}\right)}{\sqrt{\nu\pi}\Gamma\left(\frac{\nu}{2}\right)} \left(1 + \frac{x^2}{\nu}\right)^{-\frac{\nu+1}{2}}$$

nulová hypotéza H_0



Náhodné proměnné x a y jsou NEZÁVISLÉ.

Studentovo rozdělení

- **studentovo rozdělení** s ν stupni volnosti

$$f(x|\nu) = \frac{\Gamma\left(\frac{\nu+1}{2}\right)}{\sqrt{\nu\pi}\Gamma\left(\frac{\nu}{2}\right)} \left(1 + \frac{x^2}{\nu}\right)^{-\frac{\nu+1}{2}}$$

William Sealy Gosset („student“) → statistika na malém počtu vzorků



Studentovo rozdělení

- **studentovo rozdělení** s ν stupni volnosti


$$f(x|\nu) = \frac{\Gamma\left(\frac{\nu+1}{2}\right)}{\sqrt{\nu\pi}\Gamma\left(\frac{\nu}{2}\right)} \left(1 + \frac{x^2}{\nu}\right)^{-\frac{\nu+1}{2}}$$

- **gama funkce** $\Gamma(x) = \int_0^{\infty} t^{x-1} e^{-t} dt \quad x \geq 0$

$$\Gamma\left(\frac{1}{2}\right) = \sqrt{\pi}$$

$$\Gamma(n) = (n-1)! \quad n \in \mathbb{N}$$

$$\Gamma(x+1) = x\Gamma(x) \quad x \in \mathbb{R}$$




Excel `EXP (GAMMALN (x))`

ROOT `ROOT::Math::tgamma (x)`

Python `from scipy.special import gamma`

- **studentovo rozdělení** s ν stupni volnosti



$$f(x|\nu) = \frac{\Gamma\left(\frac{\nu+1}{2}\right)}{\sqrt{\nu\pi}\Gamma\left(\frac{\nu}{2}\right)} \left(1 + \frac{x^2}{\nu}\right)^{-\frac{\nu+1}{2}}$$

$$f(x|\nu = 1) = \frac{1}{\pi} \frac{1}{1 + x^2}$$

$$f(x|\nu \rightarrow \infty) \rightarrow \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right)$$

$$E[x] \equiv \mu = 0$$

$$V[x] \equiv \sigma^2 = \frac{\nu}{\nu - 2} \quad \nu > 2$$

Python `from scipy.stats import t`
`→ t.pdf(x, nu)`

ROOT `ROOT::Math::tdistribution_pdf(x, nu)`

Test korelace – studentovo rozdělení

- studentovo rozdělení

hladina signifikance P_α

Pro $P > P_\alpha$

přijmeme nulovou hypotézu

Pro $P < P_\alpha$

odmítneme nulovou hypotézu

pravděpodobnost

$$P = 2[1 - T_v(|\hat{t}(\hat{\rho})|)]$$




distribuční funkce
studentova rozdělení

konfidenční interval

$$(-T_v^{-1}(P_\alpha), T_v^{-1}(P_\alpha))$$



inverzní funkce k distribuční
funkci studentova rozdělení



Test korelace – studentovo rozdělení

- studentovo rozdělení

Příklad: $N = 39$, proměnné x, y, z

$$\hat{\rho}(x, y) = 0.694$$

$$|\hat{t}_{x,y}| = 5.867$$

$$P_{x,y} = 9 \times 10^{-7}$$

$$\hat{\rho}(x, z) = -0.111$$


$$|\hat{t}_{x,z}| = 0.679$$

$$P_{x,y} = 0.50$$

$$\hat{\rho}(y, z) = 0.059$$

$$|\hat{t}_{y,z}| = 0.360$$

$$P_{x,y} = 0.72$$



$P < 5\%$ **odmítneme** nulovou hypotézu

Proměnné x, y jsou **ZÁVISLÉ**.

$P > 5\%$ **přijmeme** nulovou hypotézu

Proměnné x, z a y, z jsou **NEZÁVISLÉ**.