

# Metoda nejmenších čtverců – lineární model

- sada naměřených hodnot  $\mathbf{x} = (x_1, x_2, \dots, x_n)$  (nezávislé proměnné)  
 $\mathbf{y} = (y_1, y_2, \dots, y_n)$  (závislé proměnné)  $y_i \in N(\mu_i, \sigma_i)$

- modelová funkce  $\lambda(x|\boldsymbol{\theta})$  (modelujeme závislost  $y(x)$ )

$$\lambda(x_i|\boldsymbol{\theta}) = \sum_{j=1}^m a_j(x_i)\theta_j = \sum_{j=1}^m A_{ij}\theta_j$$

$$\boldsymbol{\theta} = (\theta_1, \theta_2, \dots, \theta_m) \quad (\text{parametry modelové závislosti})$$

- minimalizujeme tzv. „chí kvadrát“  $\chi^2(\boldsymbol{\theta}|\mathbf{y}, \boldsymbol{\sigma}, \mathbf{x}) = \sum_{i=1}^n \frac{(y_i - \sum_{j=1}^m A_{ij}\theta_j)^2}{\sigma_i^2}$

pokud  $\sigma_i = \sigma$

$$\chi^2 = \frac{1}{\sigma^2} (\mathbf{y} - \mathbf{A}\boldsymbol{\theta})^T (\mathbf{y} - \mathbf{A}\boldsymbol{\theta})$$

obecně  $V_{ij} = \text{cov}(y_i, y_j)$

$$\chi^2 = (\mathbf{y} - \mathbf{A}\boldsymbol{\theta})^T \mathbf{V}^{-1} (\mathbf{y} - \mathbf{A}\boldsymbol{\theta})$$

# Metoda nejmenších čtverců – lineární model

- minimalizujeme tzv. „chí kvadrát“  $\chi^2(\boldsymbol{\theta}|\mathbf{y}, \boldsymbol{\sigma}, \mathbf{x}) = \sum_{i=1}^n \frac{(y_i - \sum_{j=1}^m A_{ij}\theta_j)^2}{\sigma_i^2}$

$$0 = \frac{\partial \chi^2}{\partial \theta_k} = -\frac{2}{\sigma^2} \sum_{i=1}^n \left( y_i - \sum_{j=1}^m A_{ij}\theta_j \right) A_{ik} \Rightarrow \sum_{i=1}^n A_{ik}y_i = \sum_{i=1}^n \sum_{j=1}^m A_{ik}A_{ij}\theta_j \Rightarrow \mathbf{A}^T \mathbf{y} = \mathbf{A}^T \mathbf{A} \boldsymbol{\theta}$$

- odhad parametrů  $\hat{\boldsymbol{\theta}}$

$$\text{pro } \sigma_i = \sigma \quad \hat{\boldsymbol{\theta}} = (\mathbf{A}^T \mathbf{A})^{-1} \mathbf{A}^T \mathbf{y} \equiv \mathbf{B} \mathbf{y}$$

$$\text{obecně} \quad \hat{\boldsymbol{\theta}} = (\mathbf{A}^T \mathbf{V}^{-1} \mathbf{A})^{-1} \mathbf{A}^T \mathbf{V}^{-1} \mathbf{y} \equiv \mathbf{B} \mathbf{y}$$

- odhad kovariance parametrů  $\hat{\boldsymbol{\theta}}$

$$U_{ij} = \text{cov}(\theta_i, \theta_j) \quad \mathbf{U} = \mathbf{B} \mathbf{V} \mathbf{B}^T$$

$$U_{ij}^{-1} = \frac{1}{2} \left[ \frac{\partial \chi^2}{\partial \theta_i \partial \theta_j} \right]_{\boldsymbol{\theta} = \hat{\boldsymbol{\theta}}}$$

# Metoda nejmenších čtverců – fit polynomu stupně $m$

- $n$  naměřených hodnot

$$\mathbf{x} = (x_1, x_2, \dots, x_n) \quad \mathbf{y} = (y_1, y_2, \dots, y_n)$$

$$\sigma_i = \sigma$$

- $m + 1$  parametrů modelové funkce  $\boldsymbol{\theta} = (\theta_1, \theta_2, \dots, \theta_m)$

- obecný polynom stupně  $m$

$$\lambda(x_i|\boldsymbol{\theta}) = \sum_{j=0}^m A_{ij}\theta_j = \sum_{j=0}^m \theta_j x_i^j$$

- matice  $A_{ij} = x_i^j$

$$\mathbf{A} = \begin{pmatrix} 1 & x_1 & x_1^2 & \dots & x_1^m \\ 1 & x_2 & x_2^2 & \dots & x_2^m \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_n & x_n^2 & \dots & x_n^m \end{pmatrix} \quad n \times (m + 1)$$

$$\mathbf{A}^T \mathbf{A} = \begin{pmatrix} n & \sum_{i=1}^n x_i & \sum_{i=1}^n x_i^2 & \dots & \sum_{i=1}^n x_i^m \\ \sum_{i=1}^n x_i & \sum_{i=1}^n x_i^2 & \sum_{i=1}^n x_i^3 & \dots & \sum_{i=1}^n x_i^{m+1} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \sum_{i=1}^n x_i^m & \sum_{i=1}^n x_i^{m+1} & \sum_{i=1}^n x_i^{m+2} & \dots & \sum_{i=1}^n x_i^{m+m} \end{pmatrix} \quad (m + 1) \times (m + 1)$$

- odhady parametrů

$$\hat{\boldsymbol{\theta}} = (\mathbf{A}^T \mathbf{A})^{-1} \mathbf{A}^T \mathbf{y} \quad \mathbf{U} = \frac{1}{\sigma^2} (\mathbf{A}^T \mathbf{A})^{-1} \mathbf{A}^T [(\mathbf{A}^T \mathbf{A})^{-1} \mathbf{A}^T]^T$$

# Metoda nejmenších čtverců – fit paraboly

- polynom 2. stupně ( $m = 3$ )

$$\lambda(x_i|\boldsymbol{\theta}) = \sum_{j=0}^m A_{ij}\theta_j = \theta_0 + \theta_1 x_i + \theta_2 x_i^2$$


$$\mathbf{A} = \begin{pmatrix} 1 & x_1 & x_1^2 \\ 1 & x_2 & x_2^2 \\ \vdots & \vdots & \vdots \\ 1 & x_n & x_n^2 \end{pmatrix}$$

$$\mathbf{A}^T \mathbf{V}^{-1} \mathbf{A} = \begin{pmatrix} \sum_{i=1}^n \frac{1}{\sigma_i^2} & \sum_{i=1}^n \frac{x_i}{\sigma_i^2} & \sum_{i=1}^n \frac{x_i^2}{\sigma_i^2} \\ \sum_{i=1}^n \frac{x_i}{\sigma_i^2} & \sum_{i=1}^n \frac{x_i^2}{\sigma_i^2} & \sum_{i=1}^n \frac{x_i^3}{\sigma_i^2} \\ \sum_{i=1}^n \frac{x_i^2}{\sigma_i^2} & \sum_{i=1}^n \frac{x_i^3}{\sigma_i^2} & \sum_{i=1}^n \frac{x_i^4}{\sigma_i^2} \end{pmatrix}$$

$$\hat{\boldsymbol{\theta}} = (\mathbf{A}^T \mathbf{V}^{-1} \mathbf{A})^{-1} \mathbf{A}^T \mathbf{V}^{-1} \mathbf{y} \equiv \mathbf{B} \mathbf{y}$$

$$\mathbf{U} = \mathbf{B} \mathbf{V} \mathbf{B}^T$$

$$U_{ij} = \text{cov}(\theta_i, \theta_j)$$



$$\theta_0 = 180 \pm 70$$

$$\theta_1 = 87 \pm 9$$

$$\theta_2 = -2.0 \pm 0.2$$

$$\text{cov}(\theta_1, \theta_2) = -490$$

$$\text{cov}(\theta_1, \theta_3) = 10.1$$

$$\text{cov}(\theta_2, \theta_3) = -1.72$$

- modelová funkce  $\lambda(x|\theta)$  nelineární vzhledem k parametrům  $\theta = (\theta_1, \theta_2, \dots, \theta_m)$ .

- nelineární model

$$\lambda(T|\nu_0, Q) = \nu_0 \exp\left(-\frac{Q}{kT}\right) \longrightarrow$$

- lineární model

$$\ln \lambda(T) = -\frac{Q}{kT} + \ln \nu_0 = A \frac{1}{T} + B$$

transformace  $z_i = \ln y_i$   $\sigma_{z_i} = \frac{\sigma_i}{y_i}$

$$\chi^2(\nu_0, Q|\mathbf{y}) = \sum_{i=1}^n \frac{(y_i - \lambda(T_i|\nu_0, Q))^2}{\sigma_i^2}$$

$$\frac{\partial \chi^2}{\partial Q} = 0 \quad \frac{\partial \chi^2}{\partial \nu_0} = 0$$

$$\chi^2(A, B|\mathbf{y}) = \sum_{i=1}^n \frac{(\ln y_i - \ln \lambda(T_i|A, B))^2}{\sigma_i^2 / y_i^2}$$

$$\frac{\partial \chi^2}{\partial A} = 0 \quad \frac{\partial \chi^2}{\partial B} = 0$$

- soustava nelineárních rovnic

→ numerické (přibližné řešení)

- soustava lineárních rovnic

→ analytické (přesné řešení)

# Metoda nejmenších čtverců – linearizace

Arrhenius.py



- modelová funkce  $\lambda(x|\theta)$  nelineární vzhledem k parametrům  $\theta = (\theta_1, \theta_2, \dots, \theta_m)$ .
- nelineární model

$$\lambda(T|\nu_0, Q) = \nu_0 \exp\left(-\frac{Q}{kT}\right) \longrightarrow$$

- lineární model

$$\ln \lambda(T) = -\frac{Q}{kT} + \ln \nu_0 = A \frac{1}{T} + B$$

transformace  $z_i = \ln y_i$   $\sigma_{z_i} = \frac{\sigma_i}{y_i}$



Python funkce `np.polyfit`

- modelová funkce  $\lambda(x|\theta)$  nelineární vzhledem k parametrům  $\theta = (\theta_1, \theta_2, \dots, \theta_m)$ .

- nelineární model

$$\lambda(T|\nu_0, Q) = \nu_0 \exp\left(-\frac{Q}{kT}\right) \longrightarrow$$

výsledné parametry:

$$Q = -Ak$$

$$Q = 3300 \text{ K} \cdot 1.38 \times 10^{-23} \text{ J K}^{-1} = 0.284 \text{ eV}$$

$$\sigma_Q^2 = (-k\sigma_A)^2 \Rightarrow \sigma_Q = k\sigma_A$$

$$\sigma_Q = 276 \times 10^{-23} \text{ J} = 0.017 \text{ eV} \doteq 0.02 \text{ eV}$$

$$\nu_0 = \exp(B)$$

$$\nu_0 = 24.5 \times 10^9 \text{ cm}^2 \text{s}^{-1}$$

$$\sigma_{\nu_0}^2 = [\exp(B)\sigma_B]^2 = (\nu_0\sigma_B)^2 \Rightarrow \sigma_{\nu_0} = \nu_0\sigma_B$$
$$\sigma_{\nu_0} = 7.4 \times 10^9 \text{ cm}^2 \text{s}^{-1} \doteq 7 \times 10^9 \text{ cm}^2 \text{s}^{-1}$$

- lineární model

$$\ln \lambda(T) = -\frac{Q}{kT} + \ln \nu_0 = A\frac{1}{T} + B$$

výsledky fitu:

$$A = (-3300 \pm 200) \text{ K}$$

$$B = (3.2 \pm 0.3) \ln(10^9 \text{ cm}^2 \text{s}^{-1})$$

zápis výsledku

$$Q = (0.28 \pm 0.02) \text{ eV}$$

(aktivační energie)

$$\nu_0 = (25 \pm 7) \times 10^9 \text{ cm}^2 \text{s}^{-1}$$

(difúzní koeficient pro  $T \rightarrow \infty$ )

# Metoda nejmenších čtverců – nelineární fit

sterbina.py



- difrakce na štěrbině

šířka štěrbiný

$$\lambda(\alpha|a, \alpha_0) = \left[ \text{sinc}\left(\frac{\pi a}{\lambda_0} \sin(\alpha - \alpha_0)\right) \right]^2$$

$\text{sinc}(x) = \frac{\sin x}{x}$

poloha hlavního maxima



$$\chi^2(a, \alpha_0|\mathbf{y}) = \sum_{i=1}^n \frac{(y_i - \lambda(\alpha_i|a, \alpha_0))^2}{\sigma_i^2}$$

$$a = (2.499 \pm 0.004) \mu\text{m}$$

$$\alpha_0 = (1.999 \pm 0.003)^\circ$$

Python funkce

`np.curve_fit`



# Metoda nejmenších čtverců – nelineární fit

dvojsterbina.py



- difrakce na dvojštěrbíně

šířka štěrbin  $\lambda(\alpha|a, b, \alpha_0) = \left[ \text{sinc}\left(\frac{\pi a}{\lambda_0} \sin(\alpha - \alpha_0)\right) \right]^2 \left[ \cos\left(\frac{\pi b}{\lambda_0} \sin(\alpha - \alpha_0)\right) \right]^2$

$\text{sinc}(x) = \frac{\sin x}{x}$

vzdálenost štěrbin

poloha hlavního maxima



$$\chi^2(a, b, \alpha_0|\mathbf{y}) = \sum_{i=1}^n \frac{(y_i - \lambda(\alpha_i|a, b, \alpha_0))^2}{\sigma_i^2}$$

$$a = (0.4998 \pm 0.0004) \mu\text{m}$$

$$b = (5.999 \pm 0.001) \mu\text{m}$$

$$\alpha_0 = (1.999 \pm 0.001)^\circ$$


Python funkce `np.curve_fit`

# Metoda nejmenších čtverců – chyby obou proměnných

- sada naměřených hodnot

$\mathbf{x} = (x_1, x_2, \dots, x_n)$  (náhodné proměnné s chybami  $\sigma_{x_i}$ )

$\mathbf{y} = (y_1, y_2, \dots, y_n)$  (náhodné proměnné s chybami  $\sigma_{y_i}$ )



- vzdálenost bodu  $[x_i, y_i]$  od modelové funkce  $f(x)$

$$d_i^2 = (x_i - \tilde{x})^2 + (y_i - f(\tilde{x}))^2$$

- „vážená“ vzdálenost bodu  $[x_i, y_i]$  od modelové funkce  $f(x)$

$$d_i^2 = \frac{1}{\sigma_{x_i}^2} (x_i - \tilde{x})^2 + \frac{1}{\sigma_{y_i}^2} (y_i - f(\tilde{x}))^2$$

- Taylorův rozvoj modelové funkce  $f(\tilde{x})$  v okolí bodu  $x_i$

$$f(\tilde{x}) = f(x_i) + f'(x_i)(\tilde{x} - x_i)$$


$$d_i^2 = \frac{1}{\sigma_{x_i}^2} (x_i - \tilde{x})^2 + \frac{1}{\sigma_{y_i}^2} [y_i - f(x_i) + f'(x_i)(x_i - \tilde{x})]^2$$

# Metoda nejmenších čtverců – chyby obou proměnných

- sada naměřených hodnot

$\mathbf{x} = (x_1, x_2, \dots, x_n)$  (náhodné proměnné s chybami  $\sigma_{x_i}$ )

$\mathbf{y} = (y_1, y_2, \dots, y_n)$  (náhodné proměnné s chybami  $\sigma_{y_i}$ )



- minimalizujeme „váženou“ vzdálenost

$$0 = \frac{\partial d_i^2}{\partial \tilde{x}} = -2 \frac{1}{\sigma_{x_i}^2} (x_i - \tilde{x}) - 2 \frac{f'(x_i)}{\sigma_{y_i}^2} [y_i - f(x_i) + f'(x_i)(x_i - \tilde{x})]$$

$$\Rightarrow (x_i - \tilde{x}) = - \frac{\frac{1}{\sigma_{y_i}^2} f'(x_i) [y_i - f(x_i)]}{\frac{1}{\sigma_{x_i}^2} + \frac{1}{\sigma_{y_i}^2} f'(x_i)^2}$$

- minimální „vážená vzdálenost“

$$d_i^2 = \frac{[y_i - f(x_i)]^2}{\sigma_{y_i}^2 + \sigma_{x_i}^2 f'(x_i)^2}$$

# Metoda nejmenších čtverců – chyby obou proměnných

- sada naměřených hodnot

$\mathbf{x} = (x_1, x_2, \dots, x_n)$  (náhodné proměnné s chybami  $\sigma_{x_i}$ )

$\mathbf{y} = (y_1, y_2, \dots, y_n)$  (náhodné proměnné s chybami  $\sigma_{y_i}$ )

- minimalizace „chí kvadrátu“

$$\chi^2 = \sum_{i=1}^n d_i^2 = \sum_{i=1}^n \frac{[y_i - f(x_i)]^2}{\sigma_{y_i}^2 + \sigma_{x_i}^2 f'(x_i)^2}$$


- Poznámka: Taylorův rozvoj

$$y(x + dx) = f(x + dx) \approx f(x) + f'(x)dx$$

$$\tilde{x} \rightarrow \tilde{x} + dx$$

$$y(\tilde{x}) \rightarrow y(\tilde{x} + dx) + dy = f(\tilde{x}) + f'(\tilde{x})dx + dy$$

celková chyba  $\sigma^2 = \sigma_y^2 + f'^2(x)\sigma_x^2$



# Metoda nejmenších čtverců – chyby obou proměnných

- sada naměřených hodnot  $\mathbf{x} = (x_1, x_2, \dots, x_n)$  (náhodné proměnné s chybami  $\sigma_{x_i}$ )  
 $\mathbf{y} = (y_1, y_2, \dots, y_n)$  (náhodné proměnné s chybami  $\sigma_{y_i}$ )

- modelová funkce  $f(x|a, b) = ax + b$

- minimalizace „chí kvadrátu“

$$\chi^2 = \sum_{i=1}^n \frac{[y_i - f(x_i)]^2}{\sigma_{y_i}^2 + \sigma_{x_i}^2 f'(x_i)^2}$$

$$f(x_i|a, b) = ax_i + b \Rightarrow f'(x_i) = a$$

$$\chi^2 = \sum_{i=1}^n \frac{[y_i - f(x_i)]^2}{\sigma_{y_i}^2 + a^2 \sigma_{x_i}^2}$$

